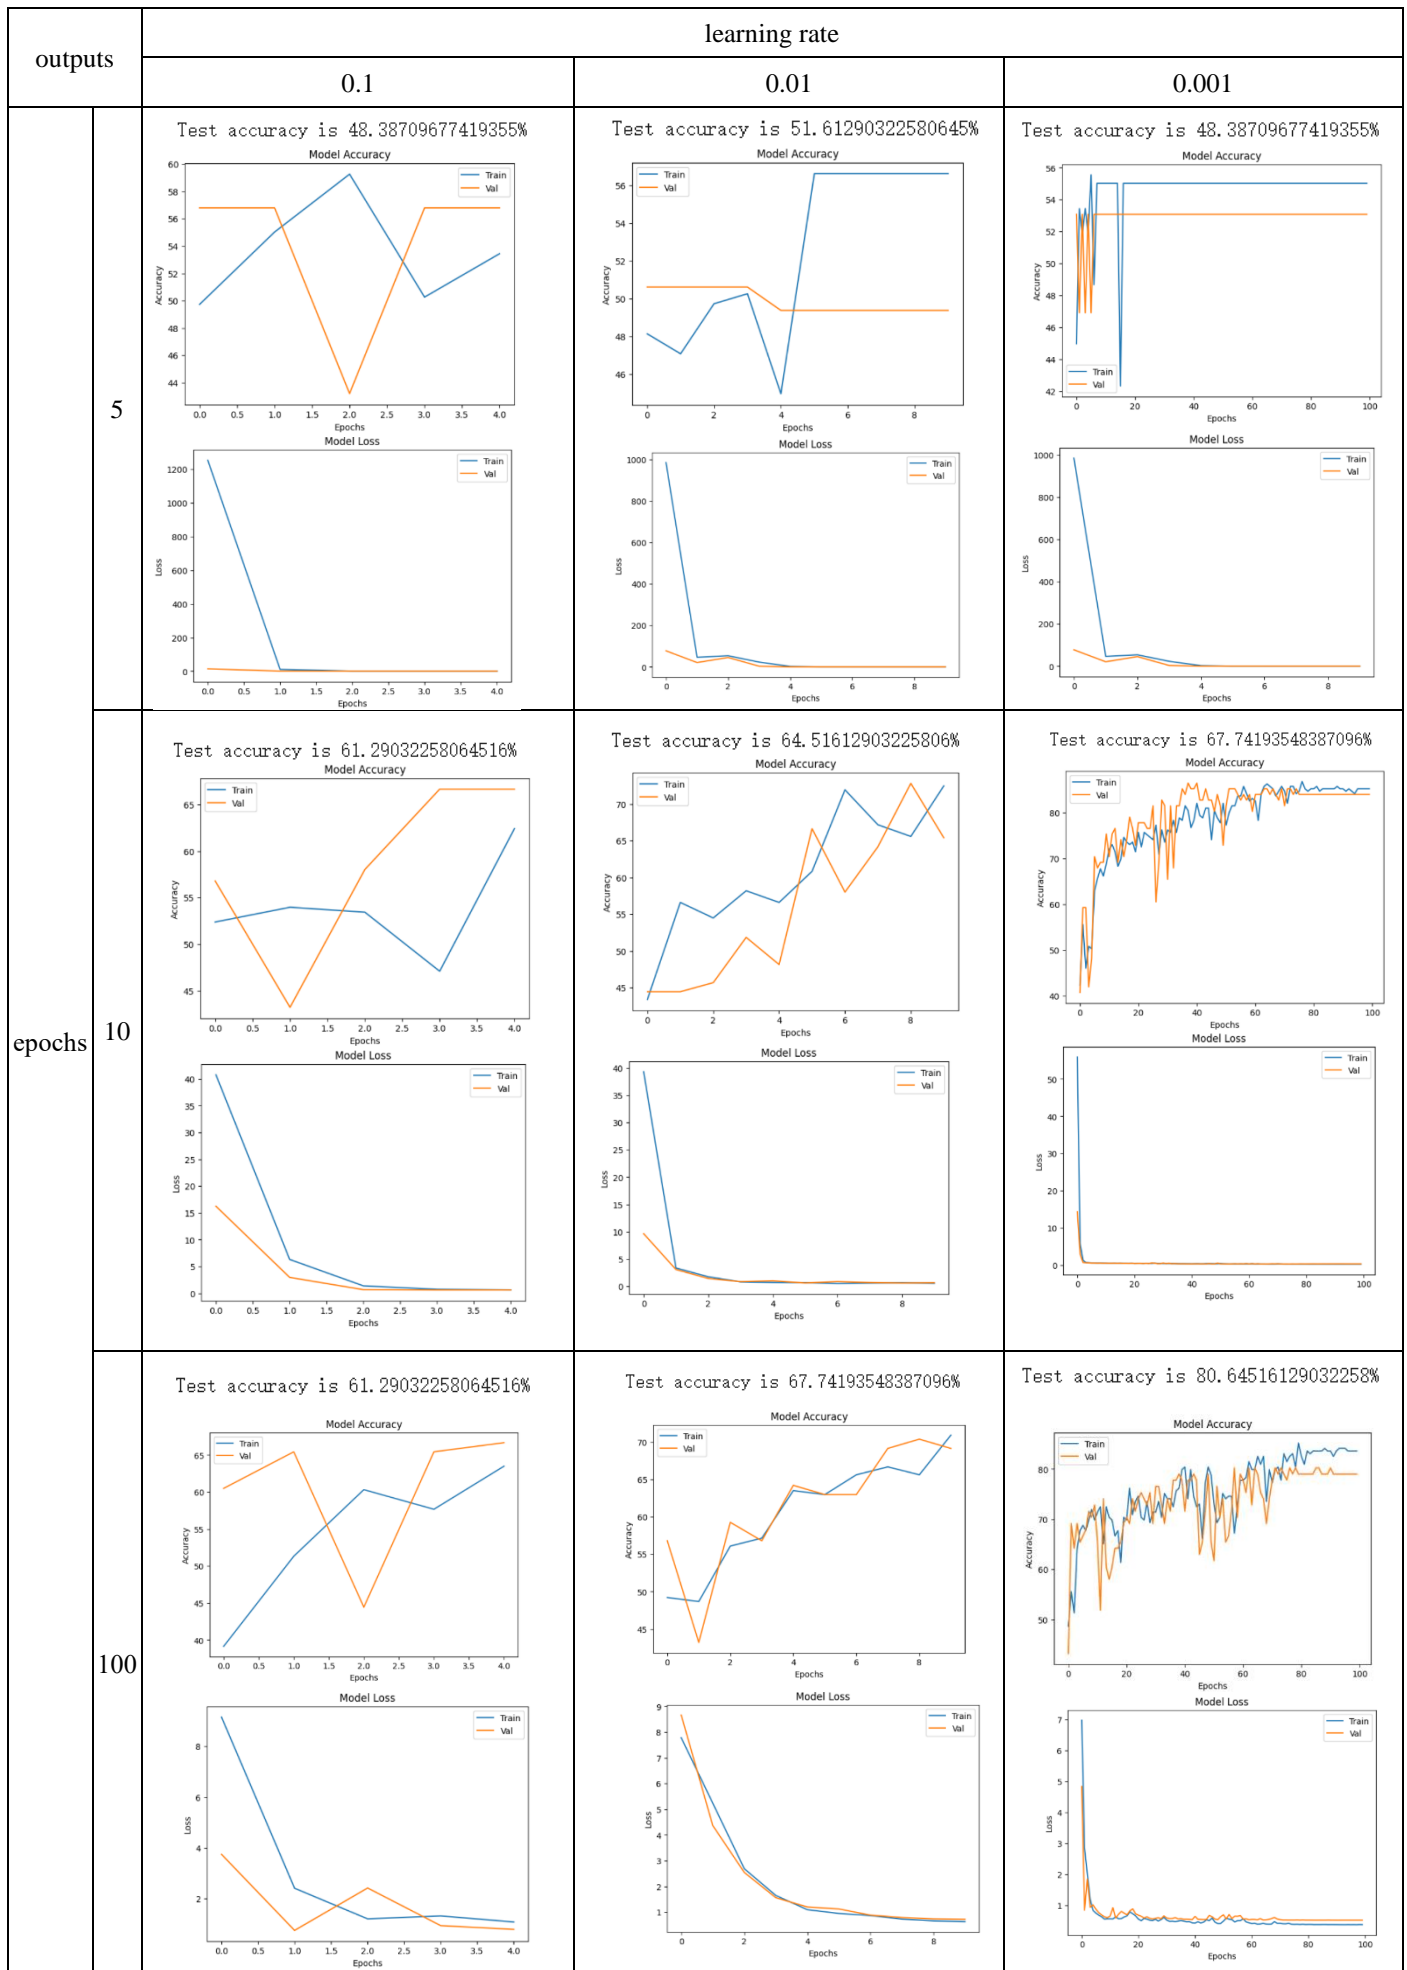


1.



這次實驗選擇調整了 learning rate 以及 Epoch 兩個參數，結果如上表所示。

從 Loss 的表現來看，當 learning rate 設定過大且搭配較簡單的模型時，會導致 Loss 迅速下降，但並未帶來有效學習；而當 learning rate 設定較小時，模型能夠更平穩地下降。另一方面，若 Epoch 設定過小，模型可能未完全收斂便結束訓練；而較大的 Epoch 則能提供更多訓練機會，尤其當 learning rate 較小時，更容易使 Loss 最終趨於穩定。

至於 Accuracy 的表現，本次實驗中，較小的 learning rate 配合較大的 Epoch 時，Accuracy 整體較高。

2. 透過此超參數實驗，我們觀察到，適當的 learning rate 能夠讓模型的 Loss 平穩下降，並在合理的時間內收斂，同時降低震盪的可能性（在此實驗中，learning rate = 0.001 為最佳選擇）。此外，足夠的 Epoch 也有助於模型的收斂。然而，在這次實驗中，當 learning rate 設為 0.001 且 Epoch 設為 100 時，我們發現模型在大約 50 個 Epoch 時就已逐漸收斂，因此並非 Epoch 數量越大越好，過多的 Epoch 反而可能導致 Overfitting 的情況。
3. 訓練集與測試集準確率的差異可能是由於 Overfitting 所引起，即模型在訓練數據上表現良好，但在未見過的數據上卻表現較差。此外，當超參數設置不當時，也容易發生 Overfitting，因為訓練集有 Label，模型會不斷調整以符合訓練集的分布，從而忽略了對未知數據的泛化能力。
4. 特徵選擇在機器學習領域中至關重要，因為現實生活中的許多資料包含不相關或冗餘的特徵。選擇有用的特徵（資訊）可以透過卡方檢定（統計方法），來評估特徵與分類標籤之間的相關性，或運用像是隨機森林（Random Forest）等機器學習算法，來計算並給出特徵的重要性分數。這樣可以提高模型的準確率，減少計算資源的消耗，並提升模型的泛化能力。

參考文獻：

- Bhargava, N., Rathore, P. S., Rajput, D., & Goswami, A. (2023, December). Unveiling Feature Significance: Enhancing Classification Accuracy using Chi-Squared Weighted Feature Selection. In *2023 2nd International Conference on Automation, Computing and Renewable Systems (ICACRS)* (pp. 12-17). IEEE.
 - Rigatti, S. J. (2017). Random forest. *Journal of Insurance Medicine*, 47(1), 31-39.
5. 在處理表格數據時，運用深度學習不一定是最佳選擇，因為表格數據的特徵之間不一定存在明顯的關聯（這與影像辨識或物件偵測有所不同）。大多數處理表格數據的常用方法是基於樹的模型。在這裡介紹一個近年來廣泛應用的概念——Bagging。其核心思想是基於多數決的原則，通過對數據進行多次隨機抽樣，訓練多個模型，並將這些模型的預測結果進行平均來決定最終結果。Bagging 的優點在於每個模型都是獨立訓練的，這使得它具有良好的並行性，從而提高了計算效率。

參考文獻：

- Breiman, L. (1996). Bagging predictors. *Machine learning*, 24, 123-140.