

1. 我選擇的產品類別為 bottle，以下為各資料描述資訊

- Number of defect classes(缺陷類別數量)：3 類
- Types of defect classes(缺陷類型)：broken_large、broken_small、contamination
- Number of images used in your dataset(總圖片數量)：292 張
- Distribution of training and test data(訓練與測試資料分布)：
 - 訓練集：good（無瑕疵）：209 張
 - 測試集：
 - ◆ good：20 張
 - ◆ broken_large：20 張
 - ◆ broken_small：22 張
 - ◆ contamination：21 張
- Image dimensions(圖片尺寸)：900 × 900 × 3



Basic Dataset Description for 'bottle'

- Number of defect classes: 3
- Types of defect classes: ['broken_large', 'broken_small', 'contamination']
- Number of images used: 292
- Distribution of training data:
 - good: 209
- Distribution of test data:
 - contamination: 21
 - good: 20
 - broken_large: 20
 - broken_small: 22
- Image dimensions: (900, 900, 3) (Height x Width x Channels)

2. 以下為原始設定下訓練之結果

超參數設定

- **Epochs:** 40
- **Optimizer:** Adam
- **Learning rate:** 1e-3
- **Batch size:** 32



Test Accuracy: 72.22%

為提升模型性能，以下是四種不同的方法嘗試

- A. 使用不同的優化器 (Optimizer)：將 Adam 替換為 AdamW 優化器 (weight decay 為 1e-4)，測得測試準確率為 75%，顯示使用 AdamW 在正則化上對模型有所幫助。
- B. 數據增強 (Data Augmentation)：使用旋轉、翻轉、色彩擾動和平移等數據增強技術，將測試準確率提升至 73.61%，這一方法有助於提高模型的泛化能力，減少過擬合風險。
- C. 修改預訓練模型(Pre-trained Model Modification)：凍結所有層並僅解凍最後一層（包括 layer4 和全連接層）進行微調。此方法取得了最佳結果，測試準確率達 87.5%，解凍高層特徵層使模型能夠更好地學習特定任務的特徵。
- D. 調整學習率調度器 (Learning Rate Scheduler)：使用學習率調度器，每 10 個 epoch 將學習率減少，測試準確率為 75%，這有助於在訓練後期細化模型學習。

優化方法	使用不同的優化器	數據增強	修改預訓練模型	調整學習率調度器
超參數設定	<ul style="list-style-type: none">Epochs: 40Optimizer: AdamWLearning rate: 1e-3Batch size: 32	<ul style="list-style-type: none">Epochs: 40Optimizer: AdamLearning rate: 1e-3Batch size: 32	<ul style="list-style-type: none">Epochs: 40Optimizer: AdamLearning rate: 1e-3Batch size: 32	<ul style="list-style-type: none">Epochs: 40Optimizer: AdamLearning rate: 1e-3Batch size: 32
output	Test Accuracy: 75.00%	Test Accuracy: 73.61%	Test Accuracy: 87.50%	Test Accuracy: 75.00%
	Test Accuracy: 75.00%	Test Accuracy: 73.61%	Test Accuracy: 87.50%	Test Accuracy: 75.00%

可以看到方法三「修改預訓練模型」獲得了最佳效果，顯示了微調預訓練模型的強大潛力。

3. (i) 長尾分佈指的是數據集中某些類別的樣本數量極多，而其他類別則很少，導致數據的分佈呈現出一個長尾狀。例如，在 MVTEC AD 數據集中，「Good」類別的樣本數量明顯高於每一種缺陷類別，這樣的數據不平衡對模型訓練和測試會帶來挑戰。
- (ii) 我找到的論文是 EQL v2: Improved Effective Training for Long-Tailed Visual Recognition¹
- 此篇研究提出一種名為 EQL v2 的改進損失函數，該方法透過自適應調整不同類別的梯度權重，使訓練過程中不會被樣本數較多的類別所主導，從而讓稀少樣本的類別獲得更多關注。
- 應用在 MVTEC AD 數據集上，可以針對「Good」類和缺陷類圖片分別調整損失權重，改善因數據不平衡而造成的模型偏差，進而提升模型對缺陷檢測的識別準確度。

¹ Tan, Jingru & Lu, Xin & Zhang, Gang & Yin, Changqing & Li, Quanquan. (2021). Equalization Loss v2: A New Gradient Balance Approach for Long-tailed Object Detection. 1685-1694. 10.1109/CVPR46437.2021.00173.

4. 在這種情況下，我們可以使用無監督學習的方法來開發異常檢測模型。由於只有「Good」類別的圖像，我們可以將其視為正常數據，並使用自監督學習方法或自編碼器來學習這些圖像的特徵。這樣，模型會學會識別「Good」圖像的潛在結構，在測試過程中可以檢測到偏離這些結構的缺陷圖像。這種方法不需要缺陷樣本的標註，適合缺乏標註數據的情況。
5. (i) 如果要進行物體檢測，我們需要準備帶有標註邊界框的數據，這樣可以標識圖像中缺陷的位置。每張圖像需要指出缺陷的具體區域。對於圖像分割，我們需要準備每個像素的標註，標註出缺陷區域的輪廓。這些數據能幫助模型學習如何精確識別並定位缺陷。
(ii) 像 YOLO 和 SAM 這類模型在大規模數據集上進行過預訓練，具備強大的物體檢測和圖像分割能力。由於這些模型能處理不同的物體或缺陷並精確定位，對於我們的異常檢測任務來說，這些模型非常適合用來進行微調。它們能夠在標註數據較少的情況下，仍然保持良好的識別和定位能力，提升我們模型在 MVTec AD 數據集上的性能。